

# Anexo de Prompts - Generación del Dataset

**Proyecto:** Inteligencia Artificial Empresa "NovaConecta"

**Responsable:** Leonardo Vera - Ingeniero de Datos y Líder de Integración

**Herramienta de IA utilizada:** Claude (Anthropic)

**Objetivo del documento:** Registrar, en orden cronológico, los prompts usados para diseñar y generar el dataset sintético (dataset\_novaconecta.csv) que sirve de insumo a los Informes 3, 4, 5 y 6.

## 1. Definición del contexto de negocio

**Prompt utilizado:**

"Necesito definir una empresa ficticia de telecomunicaciones para un proyecto de Machine Learning. Debe permitir un problema de regresión (predecir un valor continuo, como el valor de vida del cliente) y un problema de clasificación binaria (predecir abandono/churn). Ayúdame a definir el nombre, rubro y problema de negocio."

**Resultado obtenido:** Se definió a **NovaConecta**, operador de telecomunicaciones (internet y telefonía móvil), con el problema de negocio de retener clientes y estimar su valor de vida (CLV).

**Por qué este prompt primero:** Antes de generar cualquier dato, se necesita una narrativa de negocio coherente que le dé sentido a cada variable — evita generar columnas aleatorias sin justificación.

## 2. Diseño del esquema de variables

**Prompt utilizado:**

"Dado ese contexto de negocio, propón un esquema de al menos 8 variables para el dataset: variables demográficas, variables de comportamiento del cliente, y dos variables objetivo (una continua para regresión, una categórica para clasificación). Explica la lógica de negocio detrás de cada una."

**Resultado obtenido:** Esquema de 13 variables: identificador, datos demográficos (nombre, ciudad, edad, fecha de registro), variables de comportamiento (plan contratado, antigüedad, uso de datos, llamadas a soporte, cargo mensual, satisfacción) y las dos variables objetivo (valor\_vida\_cliente, abandono).

**Por qué este prompt:** Se necesitaba validar que las variables tuvieran sentido lógico y cubrieran los requisitos técnicos (+8 variables) antes de escribir código.

## 3. Generación de las variables demográficas con Faker

**Prompt utilizado:**

"Escribe el código en Python para generar, con Faker en español y semilla fija, un identificador de cliente, nombre, ciudad, edad y plan contratado para 1200 clientes."

**Resultado obtenido:** Bloque de código usando Faker('es\_ES') con Faker.seed(42) para nombres y ciudades, y np.random.choice con probabilidades (p=[0.45, 0.35, 0.20]) para simular una distribución de mercado realista entre planes Básico, Estándar y Premium.

**Por qué este prompt:** Faker resuelve bien los datos "de relleno" (nombres, ciudades) que no requieren relaciones estadísticas, pero sí requieren una semilla fija para que el dataset sea idéntico en cada ejecución.

## 4. Antigüedad derivada de la fecha de registro

### **Prompt utilizado:**

"Genera 'fecha\_registro' de forma aleatoria en los últimos 5 años, y a partir de esa fecha calcula 'antigüedad\_meses' de forma exacta (no aleatoria), tomando como referencia la fecha actual. Así garantizamos que ambas variables sean 100% coherentes entre sí."

**Resultado obtenido:** antigüedad\_meses se calcula matemáticamente como la diferencia en días entre la fecha de corte y fecha\_registro, dividida entre 30.44 (promedio de días por mes), en vez de generarse de forma independiente.

**Por qué este prompt:** Cuando dos variables están relacionadas por definición (una fecha y una antigüedad derivada de ella), lo correcto es calcular una a partir de la otra, no generarlas por separado — esto evita cualquier incoherencia temporal en el dataset.

## 5. Uso de datos dependiente del plan contratado

### **Prompt utilizado:**

"El consumo de datos ('uso\_datos\_gb') debe depender del plan contratado: los clientes Premium deben consumir considerablemente más GB que los de plan Básico, con cierta variabilidad natural dentro de cada plan. Genera esta variable usando una distribución normal distinta por cada tipo de plan."

**Resultado obtenido:** Se definieron medias y desviaciones estándar distintas por plan (Básico ~15 GB, Estándar ~40 GB, Premium ~90 GB), generando uso\_datos\_gb con np.random.normal según el plan de cada cliente.

**Por qué este prompt:** En telecomunicaciones el plan contratado determina directamente el consumo esperado de datos; modelar esto como variables independientes habría ignorado una relación de mercado fundamental.

## 6. Cargo mensual dependiente del plan y del consumo de datos

### **Prompt utilizado:**

"El cargo mensual debe tener un costo base según el plan contratado, más un componente adicional proporcional al consumo de datos, más un pequeño ruido aleatorio para variabilidad. Así el cargo mensual queda correlacionado tanto con el plan como con el uso real de datos."

### **Resultado obtenido:**

$$\text{cargo\_mensual} = \text{cargo\_base}[\text{plan}] + (\text{uso\_datos\_gb} * 0.1) + \text{ruido}$$

con tarifas base de 30 (Básico), 55 (Estándar) y 85 (Premium).

**Por qué este prompt:** Una tarifa mensual realista no es un número aislado: depende del plan contratado y escala con el consumo real. Encadenar esta variable a las anteriores asegura una historia de negocio consistente para el análisis de correlaciones en el Informe 3.

## 7. Llamadas a soporte y satisfacción del cliente

### **Prompt utilizado:**

"Genera 'num\_llamadas\_soporte' con una distribución de Poisson (la mayoría de clientes llama pocas veces, algunos llaman mucho). Luego, calcula 'satisfaccion\_cliente' de forma que decaiga cuanto mayor sea el número de llamadas a soporte y cuanto más alto sea el cargo mensual, agregando algo de ruido para que no sea una relación perfecta."

**Resultado obtenido:** num\_llamadas\_soporte se generó con `np.random.poisson(lam=2.0)` más una probabilidad de llamadas extra;

$$\text{satisfaccion\_cliente} = 9.0 - (\text{llamadas} * 0.8) - (\text{cargo} * 0.01) + \text{ruido}$$
acotada entre 1 y 10.

**Por qué este prompt:** La fricción con el cliente (llamadas repetidas a soporte) y el costo percibido (cargo alto) son las dos razones más comunes de insatisfacción en una empresa de telecomunicaciones; el dataset debía reflejar esa relación causal.

## 8. Variable objetivo categórica: Abandono (Churn)

### **Prompt utilizado:**

"Calcula 'abandono' (Sí/No) como una función logística: la probabilidad de abandono debe aumentar cuando la satisfacción es baja, el cargo mensual es alto, y la antigüedad es baja (clientes nuevos abandonan más fácil). Agrega ruido a la probabilidad para que la clasificación no sea perfecta, y que el resultado quede desbalanceado (más clientes se quedan que los que se van), como ocurre en la realidad."

**Resultado obtenido:** Se calculó `log_odds` en función de `satisfaccion_cliente`, `cargo_mensual` y `antigüedad_meses`, se transformó a probabilidad con la función sigmoide, y se sorteó el resultado final (Sí/No) comparando esa probabilidad contra un número aleatorio.

**Por qué este prompt:** El churn no es un evento aislado: en la vida real depende de qué tan satisfecho está el cliente, cuánto paga y cuánto tiempo lleva en la empresa. Modelarlo como una función logística de las variables anteriores mantiene la coherencia de negocio y, de paso, produce el desbalance de clases que exige el Informe 4 (para justificar el uso de SMOTE).

## 9. Variable objetivo continua: Valor de Vida del Cliente (CLV)

### **Prompt utilizado:**

"Calcula 'valor\_vida\_cliente' a partir del cargo mensual y la antigüedad del cliente. Si el cliente abandonó, el CLV debe limitarse a lo ya facturado históricamente; si sigue activo, debe proyectarse también su facturación futura (por ejemplo, 12 meses más). Agrega un pequeño ruido comercial."

### **Resultado obtenido:**

$$\text{valor\_vida\_cliente} = \text{cargo\_mensual} * (\text{antigüedad\_meses} + \text{proyeccion})$$

donde `proyeccion` es 0 si el cliente abandonó y 12 si sigue activo, más un ruido gaussiano leve.

**Por qué este prompt:** El CLV debe estar necesariamente ligado al churn: un cliente que se va deja de generar ingresos futuros, por lo que su valor de vida debe ser menor que el de un cliente que permanece.

Esta es la variable que conecta el problema de regresión (Informe 3) con el de clasificación (Informe 4) sobre el mismo caso de negocio.

## 10. Introducción de ruido realista para el EDA

### Prompt utilizado:

"Para que el Análisis Exploratorio de Datos (Informe 3) tenga sentido, introduce de forma controlada y reproducible ~25 valores nulos en 'uso\_datos\_gb' y ~8 outliers extremos en 'cargo\_mensual' (por ejemplo, multiplicando el valor por 4 en un pequeño subconjunto de filas)."

**Resultado obtenido:** Selección aleatoria (con semilla fija) de índices para insertar NaN en uso\_datos\_gb y multiplicar por 4 el valor de cargo\_mensual en 8 filas.

**Por qué este prompt:** Un dataset sintético sin nulos ni outliers no permite demostrar las técnicas de limpieza y detección de atípicos que exige el Informe 3. Se agregó ruido deliberado, pero acotado y reproducible.

## 11. Validación final del dataset

### Prompt utilizado:

"Ejecuta el script completo y muéstrame: la forma final del dataset, la distribución de 'abandono', el uso de datos y cargo mensual promedio por plan, la correlación entre uso de datos y cargo mensual, la correlación entre llamadas a soporte y satisfacción, el número de filas donde la antigüedad no calce con la fecha de registro, y el CLV promedio separado por abandono. Quiero confirmar que todas las relaciones de negocio quedaron reflejadas correctamente antes de exportar el CSV."

### Resultado obtenido:

| Verificación                                          | Resultado                                         |
|-------------------------------------------------------|---------------------------------------------------|
| Tamaño del dataset                                    | 1,200 filas × 13 columnas                         |
| Uso de datos promedio (Básico / Estándar / Premium)   | 15.5 / 40.5 / 91.2 GB (escalonado por plan)       |
| Cargo mensual promedio (Básico / Estándar / Premium)  | 32.1 / 60.7 / 94.6 (orden lógico por plan)        |
| Correlación uso de datos vs cargo mensual             | 0.79 (fuerte y positiva)                          |
| Correlación llamadas soporte vs satisfacción          | -0.77 (fuerte y negativa, como se espera)         |
| Filas con antigüedad incoherente vs fecha de registro | 0                                                 |
| CLV promedio: clientes que abandonan vs los que no    | 1,391 (Sí) vs 2,342 (No) — el churn reduce el CLV |
| Distribución de abandono                              | ~62% No / ~38% Sí (desbalanceado, como en la      |

| Verificación | Resultado |
|--------------|-----------|
|              | realidad) |

**Por qué este prompt:** Antes de entregar el CSV a los Devs 3, 4 y 5, era necesario auditar que el dataset cumpliera los requisitos técnicos (tamaño, nulos, balance de clases) y que todas las relaciones de negocio esperadas se reflejaran efectivamente en los datos, no solo en la intención del diseño.

## Resumen de la secuencia seguida

| #  | Etapas                          | Objetivo del prompt                                                                     |
|----|---------------------------------|-----------------------------------------------------------------------------------------|
| 1  | Contexto de negocio             | Definir la empresa ficticia y el problema a resolver                                    |
| 2  | Esquema de variables            | Diseñar las columnas y su justificación lógica                                          |
| 3  | Datos demográficos (Faker)      | Generar identificadores, texto y plan contratado                                        |
| 4  | Antigüedad ↔ fecha de registro  | Calcular la antigüedad exacta a partir de la fecha, sin aleatoriedad independiente      |
| 5  | Uso de datos ↔ plan             | Escalar el consumo de datos según el plan contratado                                    |
| 6  | Cargo mensual ↔ plan y consumo  | Calcular la tarifa a partir del plan y el consumo real                                  |
| 7  | Soporte ↔ satisfacción          | Modelar la satisfacción en función de la fricción de soporte y el cargo                 |
| 8  | Abandono (churn)                | Calcular la probabilidad de abandono como función logística de las variables anteriores |
| 9  | Valor de vida del cliente (CLV) | Ligar el CLV al cargo, la antigüedad y el estado de abandono                            |
| 10 | Ruido realista                  | Insertar nulos y outliers para el EDA                                                   |

| #  | Etapas           | Objetivo del prompt                                                             |
|----|------------------|---------------------------------------------------------------------------------|
| 11 | Validación final | Confirmar con métricas concretas que todas las relaciones de negocio se cumplen |

Esta secuencia asegura que el dataset no se generó de forma arbitraria, sino siguiendo un proceso reproducible, documentado y con sentido de negocio de principio a fin: cada variable se construye explícitamente a partir de las anteriores, replicando cómo funcionaría realmente una empresa de telecomunicaciones. Esto garantiza que los seis informes (EDA, regresión, clasificación, clustering, reducción de dimensionalidad) cuenten la misma historia analítica sobre los mismos clientes, tal como lo exige el rol de Ingeniero de Datos dentro del proyecto.