

Definicionn de la Empresa Ficticia NovaConecta

Definición de la Empresa Ficticia — NovaConecta

Proyecto: Machine Learning aplicado a retención y valor de cliente (Gamarra)

Responsable: Leonardo Vera — Ingeniero de Datos y Líder de Integración

Documento: Caracterización de negocio previa a la generación del dataset sintético

1. Por qué este documento existe

Antes de generar cualquier dato, es necesario definir la empresa ficticia con el nivel de detalle suficiente para que cada variable del dataset tenga una razón de negocio explícita detrás — su rango, su distribución y sus relaciones con las demás variables. Este documento establece esa definición de forma completa, de modo que cada decisión que luego se tome en `generar_dataset.py` — un rango de edad, una probabilidad de plan, una pendiente en la función logística — se derive de una característica de negocio explícita y no de un número elegido al azar.

2. Identidad de la empresa

Atributo	Definición
Nombre	NovaConecta S.A.C.
Rubro	Operador de telecomunicaciones (Internet fijo/móvil y telefonía)
Mercado	Perú, operación urbana y semiurbana, con presencia en varias ciudades (de ahí la variable <code>ciudad</code> , generada con Faker en español)
Antigüedad de la empresa	6 años en el mercado (coherente con la ventana de <code>fecha_registro</code> , que cubre los últimos 5 años: ningún cliente puede tener una antigüedad mayor a la vida de la empresa)
Tamaño de la base analizada	1,200 clientes activos e históricos, tomados como muestra representativa de la cartera total para fines del proyecto
Fecha de corte del análisis	4 de julio de 2026 — el “hoy” desde el cual se calculan todas las antigüedades y proyecciones

Misión de negocio

Ofrecer conectividad (datos móviles/fijos y llamadas) a un mercado sensible al precio, compitiendo principalmente por relación calidad-costo y por calidad de atención al cliente — no por ser el operador más barato ni el más premium del mercado.

Problema de negocio que motiva el proyecto de ML

El área comercial de NovaConecta necesita responder dos preguntas simultáneas sobre la misma cartera de clientes: 1. **¿Cuánto vale un cliente a lo largo de su relación con la empresa?** (Valor de Vida del Cliente — problema de regresión). 2. **¿Qué clientes están en riesgo de irse a la competencia?** (Abandono / Churn — problema de clasificación binaria).

Estas dos preguntas no son independientes: un cliente que abandona deja de generar valor futuro. Por eso el dataset debe modelarlas como fenómenos conectados, no como dos tablas separadas.

3. Portafolio de productos (la base de todo lo demás)

NovaConecta comercializa **tres planes**, diseñados para distintos segmentos de consumo. Esta es la variable más importante del dataset porque, en la realidad de una telco, el plan contratado es la causa raíz de casi todo el comportamiento posterior del cliente (consumo, tarifa, e incluso su tolerancia al precio).

Plan	Segmento objetivo	Participación en la cartera	Consumo típico de datos	Tarifa base mensual
Básico	Clientes sensibles al precio, uso ligero (mensajería, redes sociales de bajo consumo)	45%	~15 GB ($\sigma \approx 4$)	S/ 30
Estándar	Hogares y profesionales con uso moderado (streaming ocasional, trabajo remoto parcial)	35%	~40 GB ($\sigma \approx 10$)	S/ 55
Premium	Alto consumo (streaming HD/4K, gaming, múltiples dispositivos)	20%	~90 GB ($\sigma \approx 20$)	S/ 85

Justificación de la distribución 45/35/20: replica una pirámide de mercado típica de una telco de gama media — la mayoría de clientes busca el plan más económico, y el segmento premium es una minoría rentable pero acotada. Esta proporción es la que después el script traduce directamente en `np.random.choice(..., p=[0.45, 0.35, 0.20])`.

Justificación de las medias de consumo: se definieron como una progresión no lineal (15 → 40 → 90 GB) porque el salto de Estándar a Premium en telecomunicaciones suele ser más agresivo que el salto de Básico a Estándar (los usuarios premium concentran consumo audiovisual pesado). La variabilidad (σ) también crece con el plan, porque a mayor consumo permitido, mayor heterogeneidad real de uso entre clientes.

4. Modelo de precios

NovaConecta cobra una **tarifa base fija por plan** más un **componente variable ligado al consumo real**, más un pequeño margen de negociación comercial (descuentos, promociones, ajustes de vendedor) que se modela como ruido:

$$\text{cargo_mensual} = \text{tarifa_base}(\text{plan}) + (\text{uso_datos_gb} \times 0.1) + \text{ruido_comercial}$$

Justificación de negocio: ningún operador cobra una tarifa plana sin relación al consumo real — existen cargos por excedentes, add-ons de datos, y ajustes. Modelar el cargo como dependiente del plan y del consumo real asegura que la

variable `cargo_mensual` no sea una copia disfrazada del plan, sino una tarifa creíble con variabilidad de mercado. Esto es lo que permite, más adelante, un análisis de correlación significativo en el Informe 3 (0.79 entre uso de datos y cargo mensual: fuerte, pero no perfecta).

5. Ciclo de vida del cliente y antigüedad

Todo cliente de NovaConecta tiene una **fecha de registro** dentro de los últimos 5 años (ventana de análisis retrospectivo razonable para una empresa de 6 años de operación). A partir de esa fecha —y solo a partir de ella— se calcula la **antigüedad en meses**, usando la fecha de corte del análisis como referencia:

$$\text{antigüedad_meses} = (\text{fecha_corte} - \text{fecha_registro}) \text{ en días} / 30.44$$

Justificación de negocio: la antigüedad no es un atributo que el cliente “tenga” de forma independiente; es una consecuencia matemática de cuándo se registró. Tratarla como una variable generada por separado habría introducido inconsistencias temporales (p. ej., un cliente “antiguo” con fecha de registro reciente), algo que un área de Datos nunca dejaría pasar en un caso real. Esta es la razón detrás del control de calidad del punto 11 del anexo original: verificar que **cero filas** tengan antigüedad incoherente con su fecha de registro.

6. Experiencia de cliente: soporte y satisfacción

NovaConecta opera un canal de atención al cliente (call center / chat) que los clientes usan cuando tienen problemas de servicio, facturación o consultas. El **número de llamadas a soporte** sigue el patrón típico de estos canales: la mayoría de clientes casi no llama, y una minoría concentra muchas llamadas (comportamiento tipo Poisson, con una cola adicional de clientes “problemáticos” que llaman con frecuencia mucho mayor al promedio).

La **satisfacción del cliente** (escala 1–10, medida vía encuestas post-atención o post-facturación) se modela como una función que **decae** con: - Más llamadas a soporte (fricción operativa: cada llamada indica que algo no funcionó a la primera). - Un cargo mensual más alto (percepción de “estoy pagando mucho por esto”).

Justificación de negocio: en telecomunicaciones, las dos causas más citadas de insatisfacción son (a) tener que llamar repetidamente para resolver algo que debería funcionar solo, y (b) sentir que la factura es cara en relación al servicio recibido. Modelar la satisfacción como dependiente de ambas variables —y no como un número aleatorio independiente— es lo que permite obtener la correlación fuerte y negativa (-0.77) que el Informe 3 necesita para justificar un análisis de fricción de servicio.

7. Abandono (Churn): cuándo un cliente se va

Un cliente de NovaConecta abandona cuando **cambia de operador o cancela el servicio**. El riesgo de abandono no es aleatorio: aumenta cuando el cliente está insatisfecho, paga una tarifa alta, y lleva poco tiempo en la empresa (los clientes nuevos aún no han desarrollado lealtad ni costos de cambio — no han “invertido” en el operador, no tienen equipos financiados, etc.).

Esto se modela con una **regresión logística de negocio** (no un modelo de ML entrenado, sino una función que codifica la relación causal esperada):

$$\text{log_odds} = 5.0 - 0.8 \cdot \text{satisfaccion} - 0.02 \cdot (-\text{cargo_mensual}) - 0.05 \cdot \text{antigüedad_meses}$$
$$\text{p_churn} = \text{sigmoide}(\text{log_odds}), \text{ con ruido para evitar separación perfecta}$$
$$\text{abandono} = \text{"Sí"} \text{ si un sorteo aleatorio} < \text{p_churn}$$

Justificación de negocio de cada coeficiente: - **Satisfacción (peso dominante, -0.8):** es el mejor predictor de churn en la literatura de telecomunicaciones — un cliente insatisfecho es, con diferencia, el que más probablemente se va. - **Cargo mensual (+0.02, efecto moderado):** el precio importa, pero pesa menos que la experiencia de servicio; un cliente satisfecho tolera pagar más. - **Antigüedad (-0.05, efecto**

protector): replica el fenómeno real de “fricción de cambio” — mientras más tiempo lleva un cliente, menos probable es que se vaya (contratos, hábito, costo percibido de migrar).

Por qué el resultado queda desbalanceado (~62% se queda / ~38% se va): en la realidad, el churn mensual/anual de una telco nunca es 50/50 — la mayoría de la cartera se mantiene. Este desbalance no es un defecto del dataset, es una característica deliberada que obliga a usar técnicas como SMOTE en el problema de clasificación (Informe 4), tal como ocurriría con datos reales de la industria.

8. Valor de Vida del Cliente (CLV)

El CLV de NovaConecta se calcula bajo una lógica financiera simple pero realista: **lo que el cliente ya pagó, más lo que se proyecta que pagará si continúa activo.**

proyeccion = 0 meses si el cliente abandonó (no hay ingresos futuros)
proyeccion = 12 meses si el cliente sigue activo (horizonte de proyección de 1 año) valor_vida_cliente =
cargo_mensual × (antiguedad_meses + proyeccion) + ruido_comercial

Justificación de negocio: el CLV es, por definición, un concepto financiero prospectivo. Un cliente que se fue no puede seguir generando ingresos, por lo que su CLV se limita a lo históricamente facturado. Un cliente activo, en cambio, tiene un valor esperado que incluye una proyección razonable a futuro (se usó un horizonte de 12 meses, un estándar común en analítica de CLV a corto/mediano plazo). Esta dependencia directa del CLV respecto al abandono es lo que conecta el problema de regresión con el de clasificación sobre la misma base de clientes: **CLV promedio de quien se queda (\$/ 2,342) es 68% mayor que el de quien se va (\$/ 1,391)**, exactamente el patrón que se esperaría de un negocio real.

9. Calidad de datos: por qué el dataset no es “perfecto”

Ninguna base de datos operativa de una empresa real está libre de errores de captura o eventos atípicos. Para que el Análisis Exploratorio de Datos (Informe 3) tenga sentido —y no sea un ejercicio artificial sobre datos ya limpios— se introdujeron dos tipos de ruido de forma controlada y reproducible (semilla fija):

Tipo de ruido	Variable afectada	Cantidad	Justificación de negocio
Valores nulos	uso_datos_gb	25 filas (~2%)	Simula fallas de sincronización entre el sistema de facturación y el sistema de medición de consumo de datos — un problema común en integraciones de sistemas de telco (rol que ocupa, precisamente, un Ingeniero de Integración).

Outliers extremos	cargo_mensual	8 filas (~0.7%), valor ×4	Simula errores de facturación o cargos excepcionales (roaming internacional, penalidades por incumplimiento de contrato, servicios adicionales facturados incorrectamente).
--------------------------	---------------	---------------------------	---

Ambos porcentajes son deliberadamente bajos (menores al 3%), porque un porcentaje mayor no sería creíble como “ruido operativo” — sería, más bien, una falla sistémica del negocio.

10. Segmento demográfico

Edad: 18 a 75 años, distribución uniforme — refleja que un servicio de conectividad básica (internet/telefonía) es transversal a casi toda la población adulta, sin sesgo etario fuerte de mercado. **Nombre y ciudad:** generados con Faker en español (es_ES) — no aportan valor predictivo por diseño; representan la parte “administrativa” de un registro de cliente real (identificación y ubicación), y se excluyen intencionalmente de cualquier modelo predictivo por no ser variables de comportamiento.

Identificador de cliente: formato NC-00001 — convención interna de NovaConecta para folios de clientes.

11. Resumen: de la empresa a las variables

Decisión de negocio	Variable(s) que origina	Relación modelada
Tres planes, pirámide de mercado 45/35/20	plan_contratado	Base de todo el resto de variables de comportamiento
Consumo esperado por plan	uso_datos_gb	Depende de plan_contratado
Tarifa base + variable por consumo	cargo_mensual	Depende de plan_contratado y uso_datos_gb
Canal de soporte con fricción típica	num_llamadas_soporte	Distribución Poisson + cola de clientes problemáticos
Satisfacción sensible a fricción y precio	satisfaccion_cliente	Depende de num_llamadas_soporte y cargo_mensual
Antigüedad como consecuencia de		Depende exactamente de

Antigüedad como consecuencia de la fecha de alta	antigüedad_meses	Depende exactamente de fecha_registro
Churn como decisión racional del cliente	abandono	Depende de satisfaccion_cliente , cargo_mensual , antigüedad_meses
CLV como valor financiero prospectivo	valor_vida_cliente	Depende de cargo_mensual , antigüedad_meses y abandono

Empresa real, no un sistema perfecto	Nulos en <code>uso_datos_gb</code> , outliers en <code>cargo_mensual</code>	Ruido operativo controlado
--------------------------------------	---	----------------------------

Esta tabla es, en esencia, el mapa de dependencias que el script `generar_dataset.py` implementa paso a paso. Ninguna variable del dataset final es arbitraria: cada una tiene una razón de negocio explícita definida **antes** de escribir una sola línea de código, tal como corresponde al inicio del proyecto.